



CORSO DI LAUREA IN INFORMATICA

Carval

Autori

Michele Antonio Annunziata

Raffaele Coppola

Luigi Auriemma

Docente

Prof. Fabio Palomba

Contents

1	Introduzione al problema	3
1.1	L'AI nel settore automobilistico	3
1.1.1	Le sfide principali	3
1.2	Il problema affrontato	3
1.3	Specifiche PEAS	3
1.3.1	Caratteristiche dell'ambiente	4
1.4	Struttura della repository	4
2	Trattamento dei dati	6
2.1	Data understanding	6
2.1.1	Raccolta dei dati	6
2.1.2	Documentazione dei dati	6
2.1.3	Esplorazione dei dati	7
2.2	Data preparation	10
2.2.1	Pulizia dei dati	10
2.2.2	Normalizzazione dei dati	12
2.2.3	Ingegneria dei dati	12
3	Sviluppo del modello	13
3.1	Selezione del modello	13
3.1.1	Fase di addestramento	13
3.2	Tecniche di valutazione	13
4	Conclusioni	14
4.1	Alcune limitazioni affrontate	14
4.2	Possibili miglioramenti	14
4.2.1	Nei dati	14
4.2.2	Nel modello	14
4.3	Considerazioni finali	14

List of Figures

1	Matrice di correlazione delle caratteristiche numeriche	9
2	Studio delle frequenze delle caratteristiche	10
3	Studio variazioni dei prezzi	11
4	Studio dei valori nulli	12

List of Tables

1	Studio dei domini delle caratteristiche	7
2	Statistiche descrittive delle caratteristiche numeriche	8

1 Introduzione al problema

1.1 L'AI nel settore automobilistico

L'intelligenza artificiale e il Machine Learning stanno rivoluzionando numerosi settori, compreso quello della valutazione automobilistica. L'analisi automatizzata dei veicoli consente di ridurre notevolmente l'incertezza e di migliorare i processi decisionali per venditori, acquirenti e istituzioni finanziarie.

1.1.1 Le sfide principali

Come qualsiasi approccio basato sull'AI, l'implementazione di un modello predittivo per la valutazione delle auto presenta alcune criticità fondamentali:

- **qualità e disponibilità dei dati.** La qualità dei dati ha un forte impatto rispetto la prestazioni del modello.
- **explainability.** Risulta essenziale l'interpretabilità del modello in modo da poter spiegare agli utenti finali come ogni caratteristica influenzi la valutazione finale.

1.2 Il problema affrontato

L'obiettivo principale del progetto è sviluppare un modello di machine learning che esegue un task di regressione per cui viene predetto il prezzo di un'auto usata sulla base di un'esperienza maturata da un dataset che include diverse caratteristiche delle vetture automobilistiche.

1.3 Specifiche PEAS

Performance. La misura di prestazione adottata prevede l'accuratezza delle stime, valutata tramite metriche come l'errore quadratico medio (MSE) o l'errore medio assoluto (MAE). Inoltre, è fondamentale la capacità del modello di generalizzare su nuovi dati, evitando fenomeni di overfitting.

Environment. L'ambiente in cui opera l'agente tiene conto delle auto rappresentate mediante una serie di caratteristiche.

Actuators. L'agente fornisce in output una stima del valore di un'auto sulla base dei dati presi in ingresso.

Sensors. L'agente riceve in input le caratteristiche dell'auto immesse dall'utente tramite tastiera o interfaccia grafica.

1.3.1 Caratteristiche dell'ambiente

Parzialmente osservabile. La completezza dello stato osservabile risulta limitata in quanto il modello non dispone di tutte le informazioni possibili riguardo ad una specifica auto o al mercato in ogni momento. Ad esempio, potrebbero mancare dettagli nascosti come la storia degli incidenti, lo stato effettivo dei componenti meccanici o variazioni imminenti del mercato.

Singolo agente. Il sistema è progettato attorno a un unico agente (il regressore) che analizza i dati e fornisce una stima del valore di un'auto. Non è previsto competizione e/o collaborazione.

Stocastico. L'ambiente presenta per la sua natura intrinseca elementi di incertezza: il valore di un'auto può essere indubbiamente influenzato da variabili esterne aleatorie, come le fluttuazioni del mercato, la domanda regionale, eventi economici o fattori temporali. Questi aspetti rendono inevitabilmente la previsione di tipo probabilistica.

Episodico. Ogni previsione sul valore di un'auto è considerata un episodio indipendente. La stima per una determinata auto non influenza direttamente le stime di altre auto.

Statico. Durante il processo di previsione, l'ambiente è statico poiché le caratteristiche dell'auto rilevate in input non cambiano durante il calcolo della stima.

Discreto. Le variabili in input (come marca, modello, anno, chilometraggio, ecc.) sono generalmente raccolte in insiemi finiti o discretizzabili.

1.4 Struttura della repository

La repository è organizzata in modo da garantire una chiara separazione logica tra dati, codice e documentazione. Di seguito viene descritta la struttura delle principali cartelle e file presenti:

- *docs*: raccoglie la documentazione e la presentazione relativa al progetto;
- *scripts*: contiene tutti gli script sviluppati per il progetto.
- *README.md*: fornisce informazioni su come installare, configurare ed utilizzare il progetto;

- *requirements.txt*: contiene la lista delle dipendenze necessarie per eseguire gli script della repository, facilitando la configurazione dell'ambiente di sviluppo.

Questa organizzazione consente una gestione efficiente del progetto, facilitando la manutenibilità e l'eventuale estensione delle funzionalità. La repository è disponibile [qui](#).

2 Trattamento dei dati

2.1 Data understanding

2.1.1 Raccolta dei dati

Per addestrare il modello di Machine Learning, il dataset di riferimento è stato acquisito dalla piattaforma Kaggle, al seguente link: <https://www.kaggle.com/datasets/tunguz/used-car-auction-prices>.

La scelta di utilizzare un dataset di Kaggle, anziché raccogliere dati autonomamente tramite web scraping o con altre tecniche, è motivata da fattori relativi alla **facilità di accesso**, in quanto l'uso di un dataset pubblico consente di garantire la riproducibilità degli esperimenti, evitando problemi legati alla legalità della raccolta dati e alla gestione di grandi volumi di informazioni eterogenee; inoltre, la raccolta di dati tramite scraping potrebbe essere un processo lungo e complesso, con rischi legati all'obsolescenza dei dati e alla necessità di una manutenzione costante degli script di raccolta.

Tuttavia, la reperibilità dei dati rimane una delle sfide principali nell'applicazione dell'IA. I dataset pubblici possono presentare limitazioni in termini di completezza e rappresentatività rispetto al mercato reale.

Limiti dei dati.

2.1.2 Documentazione dei dati

Il dataset di partenza è costituito da 558811 osservazioni caratterizzate da 16 feature.

Di seguito è riportata la lista delle caratteristiche con relativa descrizione.

- **year**: anno di produzione dell'auto.
- **make**: marca del veicolo.
- **model**: modello specifico dell'auto.
- **trim**: allestimento o versione del modello.
- **body**: tipo di carrozzeria del veicolo.
- **transmission**: tipo di trasmissione.
- **vin**: codice univoco per identificare il veicolo.

- **state**: stato di registrazione/vendita del veicolo.
- **condition**: condizione generale del veicolo.
- **odometer**: chilometraggio dell'auto.
- **color**: colore carrozzeria auto.
- **interior**: colore degli interni dell'auto.
- **mmr**: indicatore del valore di mercato su base storica.
- **sellingprice**: prezzo effettivo di vendita del veicolo (**target**).
- **saledate**: data in cui l'auto è stata venduta.

Feature	Dtype
year	int64
make	object
model	object
trim	object
body	object
transmission	object
vin	object
state	object
condition	float64
odometer	float64
color	object
interior	object
seller	object
mmr	int64
sellingprice	int64
saledate	object

Table 1: Studio dei domini delle caratteristiche

2.1.3 Esplorazione dei dati

In Tabella 2 sono riportate parametri statistici standard riguardo le caratteristiche numeriche.

	Count	Mean	Std	Min	Max
year	558,811	2010.04	3.97	1982	2015
condition	547,017	3.42	0.95	1.0	5.0
odometer	558,717	68,323.20	53,397.75	1.0	999,999
mmr	558,811	13,769.32	9,679.87	25.0	182,000
sellingprice	558,811	13,611.26	9,749.66	1.0	230,000

Table 2: Statistiche descrittive delle caratteristiche numeriche

Correlazione con il target. Nell'analisi dei dati, la matrice di correlazione è uno strumento essenziale per comprendere le relazioni tra le variabili del dataset. La correlazione misura il grado di associazione lineare tra due variabili e fornisce informazioni cruciali sulla loro dipendenza reciproca.

Il valore della correlazione varia tra -1 e 1 :

- *Correlazione positiva* ($+1$). Quando una variabile aumenta, anche l'altra tende ad aumentare.
- *Correlazione negativa* (-1). Quando una variabile aumenta, l'altra tende a diminuire.
- *Correlazione nulla* (0): Le due variabili non presentano alcuna relazione lineare.

Dall'analisi della matrice di correlazione delle caratteristiche numeriche presente in Figura 1, si osserva una forte correlazione tra la variabile mmr e sellingprice. Successivamente è spiegata la problematica di questa forte correlazione.

Il problema dei data leakage. Un aspetto critico nella costruzione del modello di machine learning è il rischio di **data leakage**. Tale problema si presenta quando un modello è capace di lavorare accuratamente in fase di addestramento, ma non in fase di rilascio. Ciò è possibile perché magari si utilizzano caratteristiche disponibili nel training ma che non saranno disponibili a "run time" (**leaky predictor**).

Nel dataset di riferimento, l'uso di mmr come variabile predittiva introduce un rischio significativo di data leakage, in quanto contiene per sua natura informazioni derivate direttamente dal target. Se il valore mmr è stato calcolato utilizzando informazioni disponibili solo dopo la vendita del veicolo, allora il modello potrebbe imparare una relazione artefatta, sfruttando dati che in una situazione reale non sarebbero disponibili al momento della valutazione del prezzo.

Per ovviare a tal inconveniente, la caratteristica mmr è stata sin da subito esclusa, così da garantire che il modello possa apprendere esclusivamente da caratteristiche disponibili ex ante la vendita del




Figure 1: Matrice di correlazione delle caratteristiche numeriche

veicolo.

Distribuzione caratteristiche numeriche. In Figura 2 sono riportati i grafici relativi alle frequenze delle caratteristiche numeriche.




Figure 2: Studio delle frequenze delle caratteristiche


Studio variazione target. In Figura 3 sono riportati dei grafici che mostrano l'andamento del valore del target (sellingprice) in funzione di alcune variabili indipendenti.

2.2 Data preparation


2.2.1 Pulizia dei dati

Nel contesto di machine learning, dati di bassa qualità possono portare a risultati fuorvianti e ad una generalizzazione scarsa, compromettendo le capacità del modello di apprendere le reali relazioni presenti tra le caratteristiche che si hanno a disposizione. Pertanto, un accurato processo di data cleaning risulta essere di vitale importanza.


Per pulizia dei dati si intende rendere i dati utilizzabili da un modello di ML e capire in particolare in che modo sopravvivere alla mancanza o al rumore dei dati di partenza




(a) Condizione contro prezzo



(b) Anno contro prezzo



(c) MMR contro prezzo



(d) Chilometraggio contro prezzo

Figure 3: Studio variazioni dei prezzi

Verifica dei valori nulli. In Figura 4 è mostrata la quantità di campioni con valori nulli per ciascuna caratteristica. La presenza di dati mancanti causa una visione non del tutto completa da parte del modello. Dunque, occorre stimare i valori dei dati mancanti sulla base di quelli disponibili (**data imputation**) oppure mitigare il problema andando a scartare basi di esperienza (rimozione di campioni o caratteristiche).

La sfida più impegnativa risiede nell'evitare l'introduzione di bias, un aspetto tutt'altro che banale. Per questo motivo, le tecniche classiche di imputazione – come l'utilizzo della media o della mediana per le variabili numeriche e l'impiego della moda per quelle categoriche – vengono affiancate a valutazioni empiriche specifiche del contesto.

Verifica dei duplicati. Lo step di verifica dei dati duplicati permette di assicurare l'unicità e la coerenza dei dati, eliminando le ridondanze che possono portare a sovra-rappresentazioni di determinate osservazioni, inficiando, ineluttabilmente, la genuinità delle predizioni del modello.

Gestione del rumore nei dati.




Figure 4: Studio dei valori nulli

2.2.2 Normalizzazione dei dati

2.2.3 Ingegneria dei dati

"PCA "

3 Sviluppo del modello

3.1 Selezione del modello

3.1.1 Fase di addestramento

Importanza delle caratteristiche

3.2 Tecniche di valutazione

4 Conclusioni

4.1 Alcune limitazioni affrontate

4.2 Possibili miglioramenti

4.2.1 Nei dati

4.2.2 Nel modello

4.3 Considerazioni finali